

ATIVIDADE FINAL

Conhecimentos necessários para o desenvolvimento da Atividade:

Monitoramento e análise de preços na web

Contextualização

Uma empresa deseja acompanhar os preços praticados no mercado para entender melhor o posicionamento de seus produtos e de seus concorrentes.

Atualmente, essa análise é feita manualmente por colaboradores que acessam diferentes sites, pesquisam os produtos e registram os preços encontrados em planilhas. Além de consumir tempo, esse processo dificulta a atualização frequente das informações e a geração de análises comparativas.

A empresa deseja avaliar a possibilidade de utilizar Web Scraping, APIs e técnicas de Data Mining para automatizar parte desse processo.

Nesta atividade, cada equipe deverá atuar como uma pequena equipe de dados responsável por desenvolver um pipeline simples de inteligência de mercado, partindo da coleta de informações disponíveis na web até a geração de análises e visualizações.

Objetivo da proposta da Atividade:

Para realizar a atividade, serão necessários conhecimentos sobre:

- fundamentos de Data Mining;
- etapas de um processo de mineração de dados;
- fundamentos de Web Scraping;

- estrutura HTML e DOM;
- seletores CSS e/ou XPath;
- requisições HTTP;
- utilização de APIs;
- bibliotecas de coleta de dados em Python;
- utilização de Requests e BeautifulSoup;
- noções básicas de Selenium, quando necessário;
- armazenamento de dados em CSV ou DataFrame;
- tratamento de valores ausentes;
- remoção de duplicidades;
- transformação e padronização de dados;
- análise exploratória de dados;
- estatísticas descritivas;
- visualização de dados;
- automação básica da coleta;
- aspectos éticos e legais relacionados à coleta de informações na web.

Descrição da atividade:

Desenvolver uma aplicação prática que integre Web Scraping e Data Mining para coletar, preparar e analisar informações reais disponíveis na internet.

Ao final da atividade, espera-se que os estudantes sejam capazes de construir um fluxo completo envolvendo:

coleta → armazenamento → limpeza → transformação → análise → visualização → geração de insights.

A atividade também busca desenvolver a capacidade crítica dos estudantes sobre os limites técnicos, éticos e legais envolvidos na coleta automatizada de dados.



Passo a passo para desenvolvimento da atividade:

Uma empresa deseja realizar um estudo de mercado comparando preços de produtos comercializados pela internet.

Cada equipe deverá escolher uma categoria de produtos e construir um pequeno processo automatizado para coletar informações disponíveis publicamente na web.

Exemplos de categorias:

- notebooks;
- smartphones;
- televisores;
- monitores;
- livros;
- jogos;
- eletrodomésticos;
- produtos de supermercado;
- produtos esportivos;
- outros produtos previamente aprovados pelo professor.

O grupo deverá coletar informações de pelo menos 30 produtos ou ofertas, provenientes de uma ou mais páginas públicas.

Para cada registro, sempre que a informação estiver disponível, deverão ser coletados pelo menos:

- nome do produto;
- preço;
- loja ou fonte;
- URL;
- categoria ou termo pesquisado.

Opcionalmente, poderão ser coletadas informações como:

- **marca;**
- **avaliação;**
- **quantidade de avaliações;**
- **preço anterior;**
- **percentual de desconto;**
- **disponibilidade.**

A atividade deverá ser desenvolvida preferencialmente em Python.

Os estudantes poderão utilizar:

- **Requests;**
- **Beautiful Soup;**
- **Pandas;**
- **Selenium, quando realmente necessário;**
- **APIs públicas, caso encontrem uma fonte adequada.**

Não é obrigatório utilizar Selenium.

Sempre que existir uma API pública e adequada para obter a mesma informação, a equipe deverá avaliar se o uso da API é mais apropriado que o scraping e justificar a decisão.

Orientações para envio da atividade:

1. Formação da equipe

Formar equipes de até 6 integrantes.

2. Definir o problema de mercado

A equipe deverá escolher:



- **uma categoria de produtos;**
- **uma pergunta que deseja responder com os dados.**

Exemplos:

Qual loja apresenta os menores preços para smartphones da categoria pesquisada?

Existe uma diferença relevante entre os preços de notebooks de diferentes marcas?

Quais produtos apresentam os maiores descontos?

Qual é a faixa de preço predominante na categoria analisada?

A pergunta deverá ser definida antes da coleta.

3. Escolher a fonte de dados

A equipe deverá selecionar uma ou mais fontes disponíveis publicamente na internet.

Antes de iniciar a coleta, deverá identificar:

- **URL da página;**
- **quais informações serão coletadas;**
- **se os dados estão diretamente no HTML;**
- **se o site utiliza conteúdo carregado dinamicamente;**
- **se existe API disponível para a mesma finalidade.**

A equipe deverá explicar brevemente por que escolheu utilizar:

- **Web Scraping;**
 - **API;**
 - **ou uma combinação das duas técnicas.**
-

4. Analisar a estrutura da página

Utilizando as ferramentas de desenvolvedor do navegador, a equipe deverá identificar onde as informações estão presentes no HTML.

Deverão ser identificados os elementos utilizados para localizar pelo menos:

- nome do produto;
- preço;
- URL do produto.

No relatório, a equipe deverá apresentar pelo menos um exemplo de seletor CSS ou XPath utilizado na coleta.

5. Implementar a coleta

Construir um script capaz de realizar automaticamente a coleta dos dados.

A coleta deverá gerar no mínimo 30 registros válidos.

O programa deverá armazenar os dados em:

- CSV;
- JSON;
- ou DataFrame posteriormente exportado para um desses formatos.

Não serão aceitas informações copiadas manualmente para a planilha como substituição da etapa de Web Scraping ou API.

6. Tornar a coleta minimamente automatizada



O código deverá ser capaz de coletar múltiplos produtos sem que o usuário precise copiar individualmente cada informação.

Caso existam múltiplas páginas de resultados, a equipe deverá implementar pelo menos uma das seguintes estratégias:

- percorrer automaticamente diferentes páginas;
- modificar parâmetros da URL;
- utilizar paginação de uma API;
- interagir com o botão de próxima página;
- utilizar uma quantidade previamente definida de páginas.

O objetivo não é realizar uma coleta de grande escala, mas demonstrar que o processo pode ser repetido automaticamente.

7. Armazenar os dados brutos

Antes de realizar qualquer tratamento, a equipe deverá salvar uma versão denominada, por exemplo:

`dados_brutos.csv`

Esse arquivo deverá representar as informações da forma mais próxima possível de como foram coletadas.

8. Realizar o pré-processamento

A equipe deverá analisar a qualidade dos dados e realizar as transformações necessárias.

Deverão ser investigados pelo menos:

- valores ausentes;
- registros duplicados;

- preços armazenados como texto;
- símbolos monetários;
- separadores de milhar e decimal;
- espaços ou caracteres desnecessários;
- inconsistências nos nomes dos produtos.

Exemplo:

R\$ 2.499,90

deverá ser transformado em um valor numérico adequado para análise.

Ao final, deverá ser gerado outro arquivo:

dados_tratados.csv

9. Caracterizar os dados

Utilizando o conjunto de dados tratado, a equipe deverá apresentar uma análise descritiva.

Calcular pelo menos:

- quantidade de registros;
- preço médio;
- preço mínimo;
- preço máximo;
- mediana dos preços.

Quando houver diferentes lojas ou marcas, apresentar também comparações entre esses grupos.

10. Realizar uma análise de Data Mining

A equipe deverá identificar pelo menos três padrões ou informações relevantes nos dados.

Exemplos:

- loja com menor preço médio;
- marca com maior preço médio;
- produto mais barato;
- produto mais caro;
- produtos com preços muito acima ou abaixo do restante;
- faixas de preço mais frequentes;
- diferença de preço entre lojas;
- relação entre avaliação e preço, caso essa informação tenha sido coletada.

Não é obrigatório utilizar algoritmos complexos de Machine Learning.

O objetivo é utilizar técnicas de análise e mineração para transformar os dados coletados em informações úteis.

11. Criar visualizações

A equipe deverá produzir pelo menos três gráficos diferentes.

Exemplos:

- gráfico de barras comparando preços;
- histograma da distribuição dos preços;
- boxplot dos preços por loja ou marca;
- ranking dos produtos mais baratos;
- gráfico de dispersão relacionando duas variáveis.

Cada gráfico deverá possuir:

- título;

- **identificação dos eixos;**
 - **legenda quando necessária;**
 - **breve interpretação.**
-

12. Produzir um pequeno dashboard ou painel

A equipe deverá organizar os principais resultados em um painel visual simples.

O painel poderá ser desenvolvido utilizando:

- **Python e Matplotlib**

O painel deverá apresentar pelo menos:

- **quantidade de produtos coletados;**
- **preço médio;**
- **menor preço;**
- **maior preço;**
- **pelo menos dois gráficos.**

Não é necessário publicar o dashboard na internet.

Uma captura de tela poderá ser apresentada no relatório.

13. Analisar aspectos éticos e legais

A equipe deverá dedicar uma pequena seção do relatório para discutir a coleta realizada.

Responder:

Os dados coletados eram publicamente acessíveis?

Existia uma API que poderia ser utilizada como alternativa?

Foram coletados dados pessoais?

A coleta poderia causar sobrecarga ao servidor?

Que cuidados deveriam ser adotados caso esse processo fosse utilizado continuamente por uma empresa?

A equipe deverá indicar pelo menos três boas práticas para uma coleta responsável.

14. Propor uma automação do pipeline

A equipe deverá explicar como o processo poderia funcionar automaticamente em um ambiente real.

Exemplo:

Todos os dias às 8h → executar coleta → salvar dados → realizar tratamento → atualizar indicadores → atualizar dashboard.

Não é obrigatório colocar o processo em produção.

Entretanto, o grupo deverá apresentar um pequeno diagrama contendo as etapas propostas.

Exemplo:

Internet → Web Scraping/API → Dados Brutos → Pré-processamento → Dados Tratados → Análise → Dashboard

15. Apresentar as conclusões

A equipe deverá responder à pergunta de negócio definida no início da atividade.

Também deverá apresentar pelo menos três insights obtidos a partir dos dados.

As conclusões deverão ser baseadas nos resultados encontrados e não apenas em opiniões dos integrantes.

Produção do vídeo

Além do relatório e do código, a equipe deverá produzir um vídeo explicativo demonstrando o desenvolvimento da atividade.

O vídeo deverá possuir duração entre 5 e 8 minutos.

Deverão ser apresentados:

- **problema escolhido;**
- **site ou fonte dos dados;**
- **estrutura da página utilizada na coleta;**
- **funcionamento do Web Scraping ou da API;**
- **exemplo do código;**
- **dados coletados;**
- **principais etapas do pré-processamento;**
- **gráficos produzidos;**
- **dashboard;**
- **principais insights;**
- **aspectos éticos e legais considerados.**

Todos os integrantes da equipe deverão participar do vídeo.

Não é necessário explicar detalhadamente todas as linhas de código.

O objetivo é demonstrar que a equipe compreende:



de onde vieram os dados, como foram obtidos, como foram tratados e como chegaram às conclusões apresentadas.

Orientações para envio da atividade

Deverão ser entregues 4 itens.

1. Relatório em PDF

O relatório deverá possuir entre 5 e 8 páginas.

Deverá conter:

- 1. capa;**
- 2. problema e objetivo da análise;**
- 3. fonte dos dados;**
- 4. método de coleta;**
- 5. pré-processamento;**
- 6. análise dos dados;**
- 7. gráficos e dashboard;**
- 8. aspectos éticos e legais;**
- 9. conclusão.**

O nome completo e a matrícula dos integrantes deverão constar na capa.

2. Código-fonte

Enviar:

- **arquivo `.ipynb`;**

ou

- arquivos `.py` utilizados na atividade.

O código deverá possuir comentários mínimos que permitam compreender suas principais etapas.

3. Base de dados

Enviar:

- `dados_brutos.csv`;
 - `dados_tratados.csv`.
-

4. Vídeo

Enviar o vídeo ou um link para:

- Google Drive;
- OneDrive;
- YouTube não listado;
- ou plataforma equivalente.

O link deverá possuir permissão de visualização para o professor.

Todos os integrantes deverão participar da apresentação.



CrITÉRIOS a serem avaliados:

CrITÉRIOS a serem avaliados

1. Definição do problema e escolha da fonte – 0,5 ponto

- clareza do problema;
- adequação da fonte de dados;
- justificativa da estratégia de coleta.

2. Implementação da coleta de dados – 1,0 ponto

- funcionamento do Web Scraping ou API;
- utilização adequada de seletores;
- automatização da coleta de múltiplos registros;
- organização do código.

3. Pré-processamento e qualidade dos dados – 0,8 ponto

- identificação de problemas;
- limpeza;
- transformação;
- organização adequada do conjunto final.

4. Data Mining, análises e visualizações – 1,0 ponto

- caracterização dos dados;
- qualidade das análises;
- gráficos;

- **identificação de padrões e insights.**

5. Pipeline, dashboard e aspectos éticos – 0,7 ponto

- **representação do pipeline;**
- **dashboard;**
- **análise ética e legal;**
- **boas práticas de coleta.**

6. Relatório e vídeo – 1,0 ponto

- **clareza do relatório;**
- **coerência das conclusões;**
- **qualidade da apresentação;**
- **domínio da atividade;**
- **participação dos integrantes.**

Total de pontuação: 5,0 pts.

Prazo para envio da atividade: 25/09/26 (Módulo B).